به نام خدا

عنوان: پروژه سوم درس هوش محاسباتی

استاد: حسین کارشناس

دستیاران استاد:

محمدامین دادگر

مهدی دارونی

اعضای گروه:

علی پورقیصری

طاها داوری

محمدامین مولوی زاده

مقدمه:

در این پروژه، با استفاده از الگوریتم ژنتیک، یک سیستم استنتاج فازی برای جداسازی داده‌های متنی اسپم و غیراسپم پیاده سازی شده است. در این پروژه از مجموعه داده SMS SpamCollection از پایگاه UCI استفاده شده است که شامل ۵۵۷۴ داده متنی می‌باشد.

روش انجام آزمایش:

برای انجام این پروژه، ابتدا مجموعه داده را خوانده و آن را به داده های آزمایش و تست به نسبت یک سوم تقسیم می‌کنیم. سپس تعدادی قانون فازی با استفاده از توابعی در ادامه توضیح داده خواهد شد می‌سازیم. سپس این مجموعه قانون را به الگوریتم ژنتیکی خود می دهیم که در آنجا بهینه ترین قوانین انتخاب می‌شوند. در الگوریتم تکاملی، کروموزوم ما نشان دهنده یک قانون می‌باشد. سپس پایگاه قانون ما که همان مجموعه والدین الگوریتم تکاملی می‌باشد، به ما بازگردانده می‌شود تا با استفاده از آنها، کلاس بندی را انجام دهیم.

در زیر کلاس‌ها و توابع به صورت مختصر توضیح داده شده است:

کلاس data_preprocessing:

این تابع مخصوص استخراج ویژگی های ایمیل‌های موجود در مجموعه داده‌ی داده شده می باشد. توابع موجود در این کلاس از قبل پیاده سازی شده بود و در اختیار ما قرار گرفت.

کلاس Fuzzy_functions:

این کلاس برای پیاده‌سازی توابع عضویت فازی و تست قواعد فازی است.

تابع `test`:

یک لیست از قواعد را به همراه داده‌های تست دریافت می‌کند و برای هر داده تست، تطبیق آن با قواعد را محاسبه کرده و برای هر کدام از دو کلاس، جمع تطبیق‌های تمام قواعد این کلاس را محاسبه می‌کند. در نهایت، این تابع برای هر داده تست، برچسب کلاسی را باز می‌گرداند که جمع تطبیق‌های آن به کلاس صفر بیشتر باشد یا به کلاس یک. سپس لیست برچسب‌ها برگردانده می‌شود که این لیست با لیست برچسب‌های اصلی مقایسه شده و دقت ما به دست می‌آید.

تابع `calculate_matching`:

برای هر قاعده و یک داده، تطبیق آن داده با قاعده را محاسبه می‌کند. در این تابع از قانون ضرب درجه عضویت استفاده شده است. البته می توان به جای ضرب از مینیمم هم استفاده کرد. سپس ورودی ما به تابع مورد نظر داده شده و درجه عضویت کل محاسبه می‌شود.

توابع `trapezius`، `gaussian`، `sigmoid` و `triangular`:

به ترتیب برای محاسبه مقدار عضویت فازی از توابع سیگموئیدی، گاوسی، ذوزنقه‌ای قائم الزاویه و مثلثی استفاده می‌کنند. در این‌جا فرمول‌های مجموعه‌های گفته شده طبق مستند نوشته است. علاوه بر این برای فهم بهتر فرمول‌ها توضیح هم داده شده‌اند. در هر تابع، `x` مقدار داده، `s` پهنای منحنی عضویت و `m` نقطه میانگین را دریافت کرده و مقدار عضویت فازی را محاسبه می‌کنند.

<u>کلاس Rule :</u>

به طور خلاصه این کلاس برای تولید قوانین فازی ساخته شده است. در این کلاس، در ابتدا با فراخوانی متد `__init__` قوانین به صورت اولیه تولید می‌شود. در این گام، با استفاده از متغیرهای ورودی `maximum_value` و `minimum_value`، با فراخوانی متد `generate_if_term`، شرط‌های `if` قوانین به صورت تصادفی تولید می‌شود که تعداد آن‌ها بین ۱ تا ۵ قرار دارد. این تابع در ادامه بیشتر توضیح داده شده است. در ادامه با فراخوانی متد `generate_class_label`، برچسب کلاس نیز به صورت تصادفی تولید می‌شود. هر قانون دارای ویژگی `fitness` نیز است که برای محاسبه با داده‌های آموزشی مورد استفاده قرار می‌گیرد. در صورتی که قانون در حال تولید فرزندان جدید باشد،`is_offspring` مقدار `True` دریافت می کند. البته مقدار پیش فرض `is_offspring` برابر `False` است.

تابع `generate_if_term`:

این تابع وضیفه ساختن قوانین تصادفی را برای ابتدای الگوریتم تکاملی دارد. به این صورت که شرط دارای 1 تا 5 متغیر می‌باشد. با توجه به اینکه کروموزوم ما یک قانون است، و این قانون شامل چندین ترم است، پس ترم های تصادفی ساخته و ابتدا برای هر ترم، x مورد نظر را اضافه می‌کنیم. سپس مقدار متغیر و پس از آن تابع عضویت را هم اضافه می‌کنیم. حال می‌بایست که m و s را هم اضافه کنیم که این دو عدد برحسب مقدار کمینه و بیشینه مقادیر ورودی تعیین می‌شوند.

کلاس genetic_algorithm:

این کلاس یک الگوریتم ژنتیک برای یادگیری قوانین فازی برای دسته‌بندی داده‌ها استفاده می‌کند. در این الگوریتم، پارامترهایی مانند تعداد نسل‌ها، ضریب جابجایی و نرخ جهش برای بهتر شدن عملکرد الگوریتم تعیین شده‌اند. هدف این کلاس ایجاد یک مجموعه قانون فازی با استفاده از محاسبات ژنتیکی و داده‌های آموزشی است. در این روش، مجموعه‌ای از قوانین فازی به صورت تصادفی ایجاد می‌شود و سپس قوانین با دقت بهتر و انطباق بیشتر با داده‌های آموزشی انتخاب می‌شوند. به علاوه، نرخ جهش و ضریب جابجایی برای ایجاد تغییرات در جمعیت قوانین تنظیم می‌شوند تا الگوریتم بتواند به یک حالت بهینه برای قوانین فازی برای دسته‌بندی داده‌ها برسد.

کلاس genetic_algorithm از توابع algorithm، max_min_for_initial_generation، mutation_if_term، mutation، selection crossover و fitness تشکیل شده است. این توابع به طور مختصر در ادامه توضیح داده شده است.

تابع `max_min_for_initial_generation`:

این تابع وظیفه گرفتن یک مقدار کمینه و بیشینه میانگین را دارد. این مقدار کمینه و بیشینه بعدا برای محاسبه m و s به کار می آید.

تابع `algorithm`:

در این الگوریتم، یک مجموعه اولیه از قوانین به صورت تصادفی ایجاد می‌شود و سپس برای هر قانون، یک امتیاز محاسبه می‌شود. بعد از آن، قوانین با بالاترین امتیاز در مجموعه اولیه انتخاب شده و در ادامه عملیات ژنتیکی را انجام می‌دهند.

در هر دوره از الگوریتم، یک انتخاب والدین انجام می‌شود و پس از آن، نسل جدیدی از فرزندان به دنیا می‌آیند. پس از آن، عملیات جهش بر روی فرزندان انجام می‌شود و در نهایت، فرزندان جدید به مجموعه والدین اضافه می‌شوند.

در هر دوره، امتیاز به صورت میانگین برای تمامی اعضای مجموعه والدین محاسبه و ثبت می‌شود. اگر فاصله این میانگین با میانگین دوره قبلی کمتر از یک مقدار کوچک تعیین شده باشد، الگوریتم متوقف می‌شود.

برای هر قانون در مجموعه والدین، یک امتیاز محاسبه می‌شود و در نهایت، نتایج الگوریتم به صورت امتیازات و مجموعه قوانین به دست می‌آید.

در نهایت، مجموعه والدین نهایی به همراه امتیازات مناسب برای تولید قوانین فازی به عنوان خروجی الگوریتم تولید می‌شود.

تابع `selection`:

این تابع به نسبت تعداد کلاس ها در ورودی، آن ها را مرتب می‌کند و سپس بهترین آنها را با توجه به اندازه ورودی انتخاب کرده و بر می‌گرداند.

تابع `crossover`:

از الگوریتم ژنتیک، با در نظر گرفتن شانسی برابر با `crossover_rate`، دو عضو از جمعیت والدین را به عنوان والدین برای تولید فرزندان جدید انتخاب می‌کند. سپس با استفاده از روش قطع تک نقطه‌ای، نیمی از قاعده‌ی if_term اول و نیمی از if_term دوم را برای تولید دو فرزند جدید با هم ترکیب می‌کند. در نهایت شانسی برابر با ۰.۵ داریم که از class_label عضو اول یا دوم استفاده کنیم. این فرزندان جدید را در لیست فرزندان (offspring) اضافه کرده و در نهایت لیست فرزندان را برمی‌گرداند.

تابع `mutation`:

در این تابع mutation rate پارامتری است که مشخص می‌کند چه میزان از فرزندان تحت تغییر قرار می‌گیرند. اگر mutation_rate برابر با صفر باشد، هیچ فرزندی تحت تغییر قرار نمی‌گیرد، و اگر برابر با یک باشد، همه فرزندان تحت تغییر قرار می‌گیرند.

این قسمت تابع mutation در الگوریتم ژنتیک است که به تعداد جمعیت فرزندان، با احتمال mutation_rate، فرزندان را تحت تغییر قرار می‌دهد.

اگر شرط random.uniform(0, 1) < 0.5 برقرار باشد، تابع mutation_if_term برای تغییر if_term فرزند فراخوانی می‌شود. در غیر این صورت، label فرزند تغییر داده می‌شود.

در نهایت، offspring را به صورت خروجی برگردانده می‌شود.

در این تابع، تابع mutation_if_term وظیفه تغییر بر روی شرطها را دارد.

نتایج به دست آمده:

نتایج به دست آمده به صورت زیر می‌باشد.

نمودار و داده های به دست آمده با crossover rate, mutation rate = 0.1

```
generation 0 average fitness: 0.24429013043659872
generation 1 average fitness: 0.25497627424211666
generation 2 average fitness: 0.25277321317426155
generation 3 average fitness: 0.2555396542393686
generation 4 average fitness: 0.33012978455015274
generation 5 average fitness: 0.4568081825084991
generation 6 average fitness: 0.46011078887040535
generation 7 average fitness: 0.5120818093198554
generation 8 average fitness: 0.5454489536314719
generation 9 average fitness: 0.5715541331494532
generation 10 average fitness: 0.6021410116367801
generation 11 average fitness: 0.6426761409645819
generation 12 average fitness: 0.6656704594278361
generation 13 average fitness: 0.6916856426451244
generation 14 average fitness: 0.7093906731688446
generation 15 average fitness: 0.7237212909711732
generation 16 average fitness: 0.7446288171323358
generation 17 average fitness: 0.7479179719081139
generation 18 average fitness: 0.7577415640286008
generation 19 average fitness: 0.7677768529043969
generation 20 average fitness: 0.7711974237323056
generation 21 average fitness: 0.7844716339779183
generation 22 average fitness: 0.787159537258129
generation 23 average fitness: 0.7950703141963592
generation 24 average fitness: 0.7955123482793357
generation 25 average fitness: 0.8065872560169374
generation 26 average fitness: 0.8091850161710014
generation 27 average fitness: 0.8113023509525809
generation 28 average fitness: 0.8162108902863807
generation 29 average fitness: 0.819089978758442
accuracy is: 0.7695652173913043
```

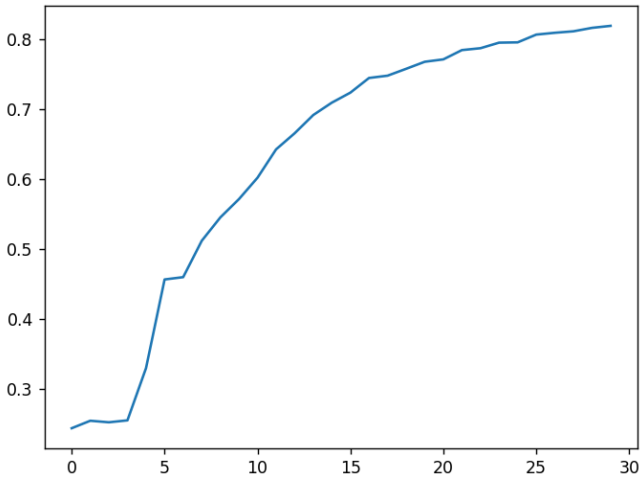

نمودار و داده های به دست آمده با crossover rate = 0.1, mutation rate = 0.9

```
generation 0 average fitness: 0.3056093419154676
generation 1 average fitness: 0.3268516587918112
generation 2 average fitness: 0.3178332641473493
generation 3 average fitness: 0.3276196858490817
generation 4 average fitness: 0.33303547852412385
generation 5 average fitness: 0.31850365436548544
generation 6 average fitness: 0.31353725080599276
generation 7 average fitness: 0.2973398270677378
generation 8 average fitness: 0.3068771158411464
generation 9 average fitness: 0.3428625935396114
generation 10 average fitness: 0.37624721220285606
generation 11 average fitness: 0.39581350224752854
generation 12 average fitness: 0.4182654524082412
generation 13 average fitness: 0.4414277876233473
generation 14 average fitness: 0.4847039604653858
generation 15 average fitness: 0.5145941245267123
generation 16 average fitness: 0.5271412623520085
generation 17 average fitness: 0.5638387443448114
generation 18 average fitness: 0.6107721369372532
generation 19 average fitness: 0.6261062828215457
generation 20 average fitness: 0.6439481084794438
generation 21 average fitness: 0.6580987597191704
generation 22 average fitness: 0.6763092409093449
generation 23 average fitness: 0.6832758047253568
generation 24 average fitness: 0.6870206754352742
generation 25 average fitness: 0.6870206754352742
accuracy is: 0.8597826086956522
```

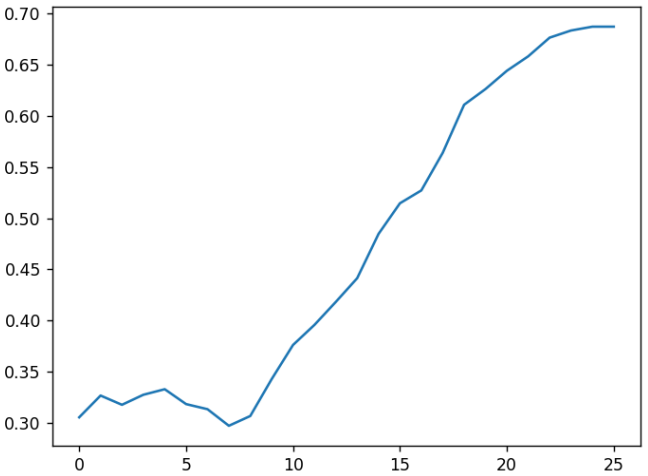

نمودار و داده های به دست آمده با crossover rate = 0.9, mutation rate = 0.1

```
generation 0 average fitness: 0.24341509828875935
generation 1 average fitness: 0.4734763816935918
generation 2 average fitness: 0.7304032015396871
generation 3 average fitness: 0.8060604793823528
generation 4 average fitness: 0.8172328332794495
generation 5 average fitness: 0.8427991422598263
generation 6 average fitness: 0.8446191578713312
generation 7 average fitness: 0.8609725190511132
generation 8 average fitness: 0.8624213699665839
generation 9 average fitness: 0.8669115341983153
generation 10 average fitness: 0.8669115341983153
accuracy is: 0.8315217391304348
```

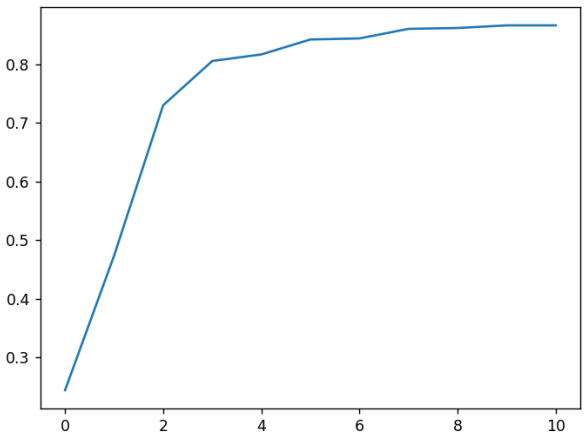

نمودار و داده های به دست آمده با crossover rate, mutation rate = 0.9

```
generation 0 average fitness: 0.2809499091181227
generation 1 average fitness: 0.5089864148800625
generation 2 average fitness: 0.710433885191662
generation 3 average fitness: 0.7664101340358519
generation 4 average fitness: 0.8016133583171714
generation 5 average fitness: 0.8250442638155147
generation 6 average fitness: 0.8650440642485292
generation 7 average fitness: 0.8784087259949334
generation 8 average fitness: 0.8850335272864506
generation 9 average fitness: 0.9025835163742397
generation 10 average fitness: 0.9198501546968585
generation 11 average fitness: 0.92187392026137
generation 12 average fitness: 0.92879022813305
generation 13 average fitness: 0.9773266836706003
generation 14 average fitness: 0.980373942528692
generation 15 average fitness: 0.9885110020592239
generation 16 average fitness: 0.9934966462069116
generation 17 average fitness: 0.9934966462069116
accuracy is: 0.8510869565217392
```

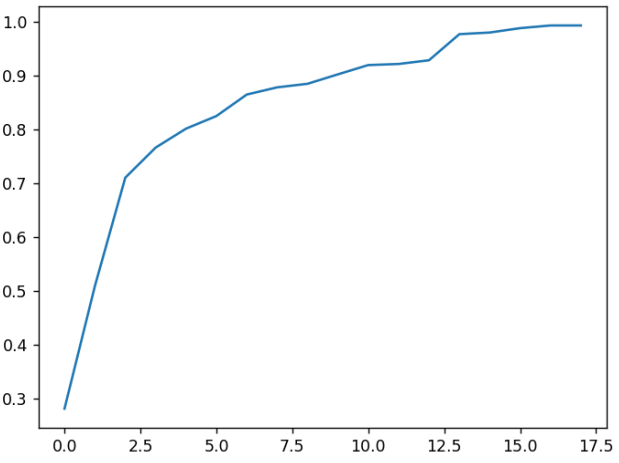

نمودار و داده های به دست آمده برای استفاده از min به جای ضرب برای درجه عضویت

```
generation 1 average fitness: 0.22978549119398772
generation 2 average fitness: 0.3725694812263465
generation 3 average fitness: 0.43118256207331707
generation 4 average fitness: 0.5477470756292588
generation 5 average fitness: 0.5791323471272302
generation 6 average fitness: 0.5937994928561001
generation 7 average fitness: 0.5950908901675747
generation 8 average fitness: 0.6013134294406641
generation 9 average fitness: 0.6092997204465134
generation 10 average fitness: 0.6119116955730792
generation 11 average fitness: 0.6119116955730792
accuracy is: 0.8771739130434782
```

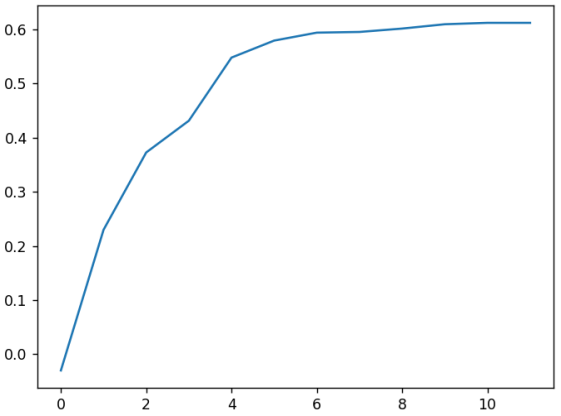

نمودار و داده های به دست آمده با اندازه پایگاه قانون 50 تایی

```
generation 0 average fitness: 0.5929992486751502
generation 1 average fitness: 0.854880149454944
generation 2 average fitness: 0.9326738348743904
generation 3 average fitness: 0.9817100973162282
generation 4 average fitness: 0.9895010321322646
generation 5 average fitness: 1.0
generation 6 average fitness: 1.0
accuracy is: 0.8016304347826086
```

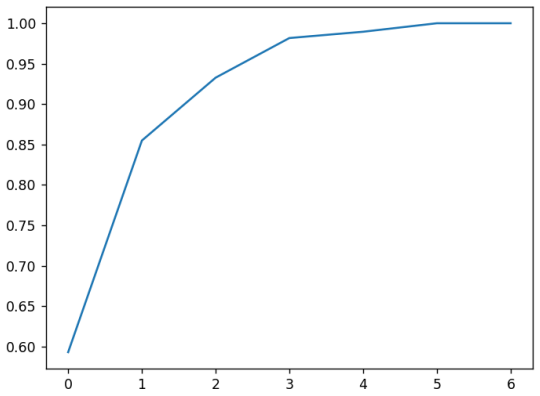

نمودار و داده های به دست آمده با اندازه پایگاه قانون 100 تایی

```
generation 0 average fitness: 0.5191087507228977
generation 1 average fitness: 0.8178942426053128
generation 2 average fitness: 0.9173306985743547
generation 3 average fitness: 0.9533254472125888
generation 4 average fitness: 0.9715209944004798
generation 5 average fitness: 0.9871913131829704
generation 6 average fitness: 0.9955061426273024
generation 7 average fitness: 0.9989326673607393
generation 8 average fitness: 0.9997385653974833
generation 9 average fitness: 0.9997688937065582
generation 10 average fitness: 0.9999004424864688
generation 11 average fitness: 1.0
generation 12 average fitness: 1.0
accuracy is: 0.8586956521739131
```

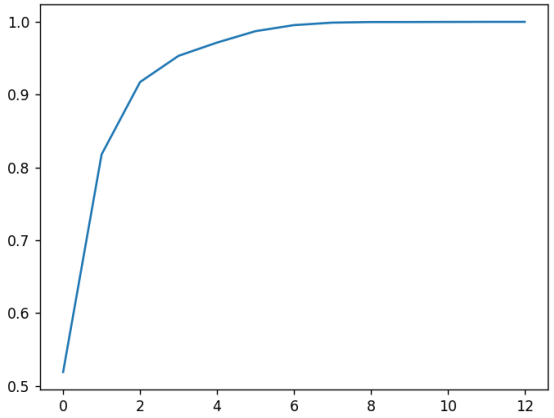

نمودار و داده های به دست آمده با اندازه پایگاه قانون 500 تایی

```
generation 0 average fitness: 0.48106579438993047
generation 1 average fitness: 0.7265628455261124
generation 2 average fitness: 0.8817892362322227
generation 3 average fitness: 0.9322623284934066
generation 4 average fitness: 0.9540674943110029
generation 5 average fitness: 0.9540674943110029
accuracy is: 0.8690217391304348
```

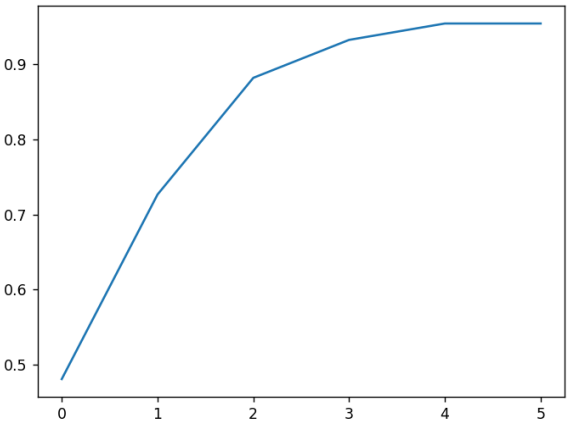

تحلیل نتایج:

برای داده‌های به دست آمده از mutation rate و crossover rate به این نتیجه می‌رسیم که با تغییرات این دو یه نسبت خاص و خوبی می‌توان دقت را افزایش داد.

میزان crossover rate بیشتر و mutation rate کمتر به ما دقت بهینه را می‌دهد.

کمینه گرفتن به جای ضرب در محاسبه درجه عضویت، دقتی کمی بهتری با توجه به اشکال به ما می‌دهد.

هرچه تعداد قانون های مجموعه قانون فازی بیشتر باشد، دقت بالاتر می رود ولی باید توجه کرد که زمان محاسبه افزایش می‌یابد.

پیشنهاد:

با توجه به مدت زمان طولانی بودن انتخاب ویژگی (feature selection) می‌توان با یکبار خواندن اجرای آن و ذخیره در فایل، دفعات بعد بدون معطلی ویژگی‌ها را خواند.

اگر مجموعه داده شامل تعداد یکسانی از داده‌های متنی اسپم و غیراسپم باشد. کار ما در انجام الگوریتم راحت تر می‌باشد.

شاید بتوان برای درنظر گرفتن قوانین اولیه یک سری شروطی در نظر گرفت که بهینه‌تر باشد.

شاید نرخ جهش فعلی که ثابت است مناسب الگوریتم نباشد، بنابراین می‌توان از نرخ جهش پویا استفاده کرد که بر اساس برازندگی قوانین نسل‌های قبل به دست آمده باشد.

منابع:

/https://chat.openai.com/

/https://treatta.com/genetic-algorithms-introductio

Machine Intelligence - Lecture 18 (Evolutionary Algorithms) - YouTube